CLASSIFICAÇÃO DE FALHAS EM MÁQUINAS ROTATIVAS UTILIZANDO “K-NEAREST NEIGHBORS” BASEADO EM ATRIBUTOS NO DOMÍNIO DO TEMPO E DA FREQUÊNCIA A PARTIR DE SINAIS DE VIBRAÇÃO TRI-AXIAIS

JOSÉ LUIZ LOPES (FATEC Deputado Ari Fossen - Jundiaí)
jose.lopes5@aluno.cps.sp.gov.br

Orientador

ARGEMIRO PENTIAN JUNIOR (Centro Paula Souza)
argemiro.pentian@cps.sp.gov.br

RESUMO

Com o advento da Indústria 4.0, torna-se mandatória a transição da Manutenção Baseada em Condição (CBM) com a monitoração de condições de operação e alarmes de alteração baseados em limites pré-estabelecidos para a Manutenção Preditiva para prover um diagnóstico cada vez mais precoce do estado de falha utilizando da Inteligência Artificial, em especial dos algoritmos de Aprendizado de Máquina (Machine Learning), cada vez mais disponíveis. Com este objetivo, este trabalho propõe uma metodologia para diagnosticar as condições de saúde e falha em máquinas rotativas, fundamentada na integração entre o processamento digital de sinais e o algoritmo K-Nearest Neighbors (KNN). A abordagem utiliza a Resultante Euclidiana para a fusão de sinais vibratórios triaxiais, preservando em um único sinal os comportamentos físicos. Continua com a extração de atributos híbridos nos domínios do tempo e da frequência, submetidos ao refinamento estatístico via Amplitude Interquartílica (IQR) e ao escalonamento Z-Score. Na análise espectral das harmônicas via Transformada Rápida de Fourier (FFT) nota-se forte relevância das três primeiras harmônicas, provada na correlação de r = 0,55 da 3ª harmônica, consolidando-a como o principal descritor de severidade. Como resultado, o classificador KNN atingiu uma acurácia de 98,44%, com destaque para a especificidade de 100%, eliminando a ocorrência de alarmes falsos, enquanto a sensibilidade atingiu 97,14%. O estudo demonstra que uma engenharia de atributos simples, aliada ao tratamento estatístico de dados, permite que modelos de baixa complexidade computacional ofereçam uma solução confiável e eficiente para diagnóstico preditivo em máquinas industriais.

PALAVRAS-CHAVE: Diagnóstico de falhas, Máquinas rotativas, Análise de vibração, Aprendizado de máquina, K-Nearest Neighbors.

ABSTRACT

With the advent of Industry 4.0, transitioning from Condition-Based Maintenance (CBM)—which relies on operating condition monitoring and change alarms based on pre-established thresholds—to Predictive Maintenance has become mandatory. This evolution aims to provide increasingly early fault diagnosis by leveraging Artificial Intelligence, particularly the growing availability of Machine Learning algorithms. To this end, this paper proposes a methodology to diagnose health and fault conditions in rotating machinery, grounded on the integration of digital signal processing and the K-Nearest Neighbors (KNN) algorithm. The approach utilizes the Euclidean Resultant for the data fusion of triaxial vibration signals, preserving physical behaviors within a single signal. It proceeds with the extraction of hybrid time- and frequency-domain features, which are subjected to statistical refinement via Interquartile Range (IQR) and Z-Score scaling. Spectral harmonic analysis via Fast Fourier Transform (FFT) reveals strong relevance across the first three harmonics, backed by a correlation of r = 0.55 for the 3rd harmonic, consolidating it as the primary descriptor of severity. As a result, the KNN classifier achieved an accuracy of 98.44%, highlighting a specificity of 100%, which eliminates the occurrence of false alarms, while sensitivity reached 97.14%. This study demonstrates that a simple feature engineering approach, combined with statistical data treatment, enables low computational complexity models to deliver a reliable and efficient solution for predictive diagnosis in industrial machinery.

KEYWORDS: Fault diagnosis; Rotating machinery; Vibration analysis; Machine learning; K-Nearest Neighbors.

1. INTRODUÇÃO

Atualmente, a Indústria 4.0 define a manufatura inteligente, sob esta visão, surge o desafio de diagnosticar falhas em máquinas industriais ancorado em dados e nos algoritmos de Aprendizado de Máquina, logo o conceito de Manutenção Preditiva passa a encarar a responsabilidade para decidir sobre as ações a serem tomadas de manutenção não mais em inspeções e monitoramentos, mas em Inteligência Artificial (Gawde et al., 2023).

Entre as técnicas disponíveis, a medição de vibração é uma das mais amplamente utilizadas para a detecção de defeitos em máquinas rotativas que usam rolamentos e engrenagens com métodos de análise nos domínios do tempo e da frequência (Tandon; Choudhury, 1999).

Para a análise dos sinais de vibração é necessário conhecer quais são os importantes indicadores dos níveis de vibração que sofrem significativa alteração de valores para indicar estados de falha. Para isto o uso de uma engenharia de atributos é fundamental para definição, no domínio do tempo, de valores da estatística básica e avançada como Amplitude do valor eficaz (Root Mean Square RMS), Fator de Crista e Curtose, por análise da Função de Densidade de Probabilidade (PDF). Outros valores no domínio da frequência, são obtidos com a conversão dos sinais de vibração através da FFT, que se mostra um método comum de análise de detecção de falha em máquinas rotativas, e torna possível a captura das amplitudes das frequências dominantes que caracterizam a presença de defeitos devido a detecção de impactos repetitivos nos elementos rotativos (Caesarendra; Tjahjowidodo, 2017)

Neste contexto para a classificação de falhas, o uso de algoritmos de aprendizado de máquina, como o KNN, é determinante para um resultado de sucesso. O processo inclui duas fases, a de treino e a de teste. Sendo que fase de treino determina os K vizinhos mais próximo e a fase de teste determina a classe a qual o vizinho testado pertence. O KNN encontra os vizinhos mais próximos de uma observação usando a distância Euclidiana padrão, então se a distância do ponto sob teste em relação a um vizinho K é a mais próxima dentre outros vizinhos, esta observação do ponto sob teste é classificada (Safizadeh; Latifi, 2014).

Portanto, a proposta deste estudo é apresentar uma metodologia de diagnóstico de falhas em máquinas rotativas simples que foca na aplicação de poucos recursos computacionais como uma engenharia de atributos que emprega a Resultante Euclidiana, estatística básica para obter atributos no domínio do tempo, FFT para capturar atributos no domínio da frequência, normalização estatística dos dados por Z-Score, análise estatística para eliminar dados fora dos limites estatísticos (“outliers”) e algoritmo de aprendizado de máquina KNN para classificar falhas e alcançar alto índice de acurácia.

2. MATERIAIS E MÉTODOS

Neste estudo foi utilizada uma base de dados constituída por registros de sinais de vibração triaxiais obtidos a uma taxa de amostragem de 1000 Hz de motores de indução de 45 kW, cuja rotação foi fixada em 2980 RPM após validação por meio de inspeção do espectro de frequência (FFT), confirmando a localização do primeiro pico harmônico (1X) e o escorregamento inerente à carga. Este conjunto de dados provém do repositório público Kaggle (Vibration Faults “dataset” for Rotating Machines) sendo formado por 220 arquivos de 5 segundos cada um, dos quais 103 representam a condição operacional “Saudável” e 117 retratam a condição de "Falha" (Kafeel et al., 2021).

Inicialmente, os sinais de vibração adquiridos de forma independente nos eixos 1, 2 e 3 foram unidos em um sinal único por meio da resultante de distância Euclidiana. Esta etapa de fusão de dados foi realizada para converter a resposta triaxial em um vetor amplitude, o que permite capturar a energia total da vibração do sistema independentemente da orientação

direcional da falha (Kafeel et al., 2021). A vantagem da fusão dos dados coletados acarreta uma análise ao mesmo tempo ampla e unificada da situação real da máquina (Gawde et al., 2023).

A partir do sinal consolidado pela Resultante Euclidiana, extraíram-se os atributos RMS, Fator de Crista e Curtose, derivados da análise da Função Densidade de Probabilidade (PDF). O RMS quantifica a energia eficaz e severidade da vibração, enquanto o Fator de Crista e a Curtose identificam picos impulsivos e alterações na forma da distribuição causadas por impactos em estágios iniciais de falha (Cerrada et al., 2018). A extração destes atributos relevantes possibilita sua utilização para determinar a saúde do sistema (Gawde et al., 2023).

Em seguida, a extração de atributos no domínio da frequência foi realizada por meio da FFT com base no sinal da Resultante Euclidiana de cada arquivo. Os atributos retirados foram as frequências harmônicas (X) que agem como assinaturas de defeitos específicos: a 1X fundamental indica desbalanceamento residual ou de massa na direção radial. O desalinhamento angular e paralelo se manifesta através das 1X e 2X. Já folgas mecânicas e impactos excitam harmônicas superiores como 3X. Logo, monitorar o trio 1X, 2X e 3X permite rastrear a evolução desde o desbalanceamento básico até severos desalinhamentos e folgas estruturais (Wang; Gao, 2006).

Para otimizar a eficiência computacional do algoritmo FFT, os sinais foram segmentados em janelas fixas com 4096 pontos, respeitando a condição de potência de dois (2^{12}), que assegura que as harmônicas do sinal periódico sejam concentradas em linhas espectrais únicas e processadas com máximo desempenho. Visando mitigar o fenômeno de vazamento espectral decorrente da descontinuidade nas extremidades dos blocos de dados, aplicou-se a função Hanning antes da transformação para o domínio da frequência (Randall; Antoni, 2011).

Na sequência, aplicou-se o método da Amplitude Interquartílica (IQR) sobre os dados normalizados de RMS e foram estabelecidos, para o grupo "Saudável", o limite inferior (Q1-1,5*IQR) e o superior (Q3+1,5*IQR) (Tukey; Anscombe; Hoaglin, 1977), assumindo que somente 0,7% da distribuição normal seriam "outliers" (Mazarei et al., 2025). Em seguida, os "outliers" superiores foram removidos, totalizando 7 amostras, para redução de falsos positivos no diagnóstico de falhas, resultando em um conjunto de dados ("dataset") com 213 amostras para o aprendizado de máquina. Para que os atributos calculados possam ser utilizados no algoritmo KNN é necessário que sejam escalonados de forma padronizada. Então foi empregado o escalonamento Z-Score, que supera consistentemente as técnicas de escalonamento Min-Max e Escala Decimal quando empregado com KNN (Pagan; Zarlis; Candra, 2023), transformando-os em uma distribuição de média zero e desvio padrão unitário trazendo todos os atributos para a mesma escala.

Para a classificação dos estados de falha, utilizou-se o algoritmo KNN, onde a classe de cada amostra é determinada pela proximidade de seus K vizinhos no espaço de atributos (Gawde et al., 2023). O conjunto de dados foi dividido em 70% para treino e 30% para e teste (Kumar; Manjunath, 2022) e ajustado para K igual a 5, pois apresentou alta acurácia e menor variância comparado a K igual a 3 (James et al., 2013). O KNN foi selecionado por sua alta acurácia de 98,61% (Xia et al., 2018), sua simplicidade e baixos requisitos computacionais (Baraldi et al., 2016) e pela facilidade de execução de novos testes com novos dados (Jablon et al., 2021).

A estruturação do fluxo de análise por meio de um pipeline automatizado é indispensável para garantir o rigor metodológico em aplicações de aprendizado de máquina, uma vez que a separação inadequada entre dados de treinamento e validação pode introduzir fenômenos de vazamento de dados ("data leakage"), comprometendo a estimativa real de generalização do modelo. Nesse contexto, o encapsulamento das etapas de transformação de dados, padronização e ajuste de hiperparâmetros em uma única estrutura de validação cruzada impede que informações do conjunto de teste sejam utilizadas durante o treinamento, assegurando maior confiabilidade estatística e reprodutibilidade experimental (Hamdan et al., 2024).

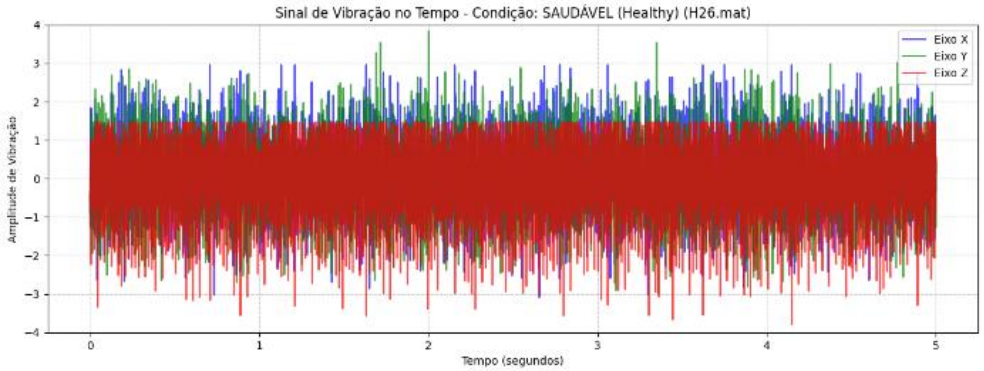
O pipeline foi desenvolvido em ambiente Python (versão 3.10), utilizando bibliotecas consolidadas na literatura científica. A manipulação matricial e o cálculo dos descritores estatísticos no domínio do tempo foram realizados com NumPy (v1.24), enquanto o processamento espectral utilizou scipy.fft da biblioteca SciPy (v1.10). As etapas de padronização Z-Score (StandardScaler), classificação KNN (KNeighborsClassifier), validação cruzada estratificada K-Fold (k=5) e otimização de hiperparâmetros por busca exaustiva em grade (GridSearchCV) foram implementadas com Scikit-Learn (v1.2), garantindo avaliação consistente e livre de vazamento de dados. Por fim, as visualizações gráficas das distribuições probabilísticas, boxplots e espaços de estados foram produzidas utilizando Matplotlib (v3.7) e Seaborn (v0.12).

3. RESULTADOS E DISCUSSÃO

3.1 Sinal da Vibração Saudável e com Falha no tempo

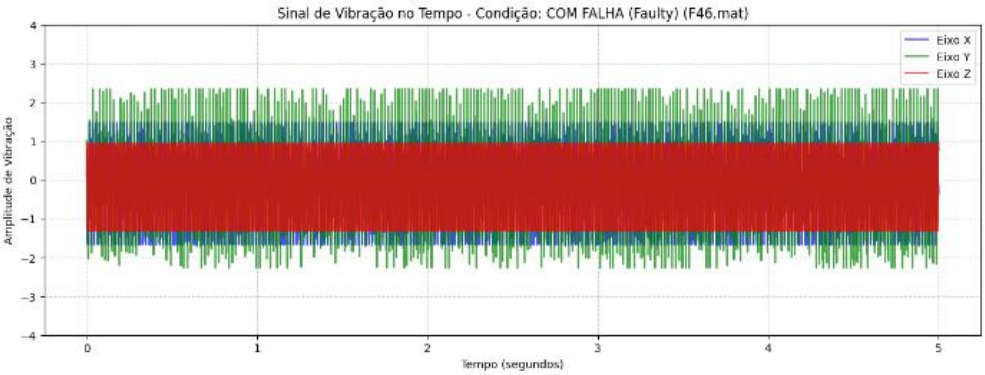
A análise inicial dos sinais de vibração no domínio do tempo foi realizada a partir dos registros brutos dos 3 sinais triaxiais extraídos diretamente dos arquivos originais, funcionando como uma triagem qualitativa para observação do comportamento "Saudável" (Figura 1) e "Falha" (Figura 2). Nesta fase, a observação não se prende a valores físicos absolutos ou escalas estatísticas, uma vez que os sinais brutos representam registros pontuais da amostra total e ainda não passaram por processos de normalização e estatísticos que levam em conta toda amostra. No entanto, a inspeção visual revela formas distintas para os sinais de "Saudável" e "Falha".

Figura 1 – Sinal de Vibração no Tempo – Condição Saudável



Fonte: Própria

Figura 2 – Sinal de Vibração no Tempo – Condição Com Falha

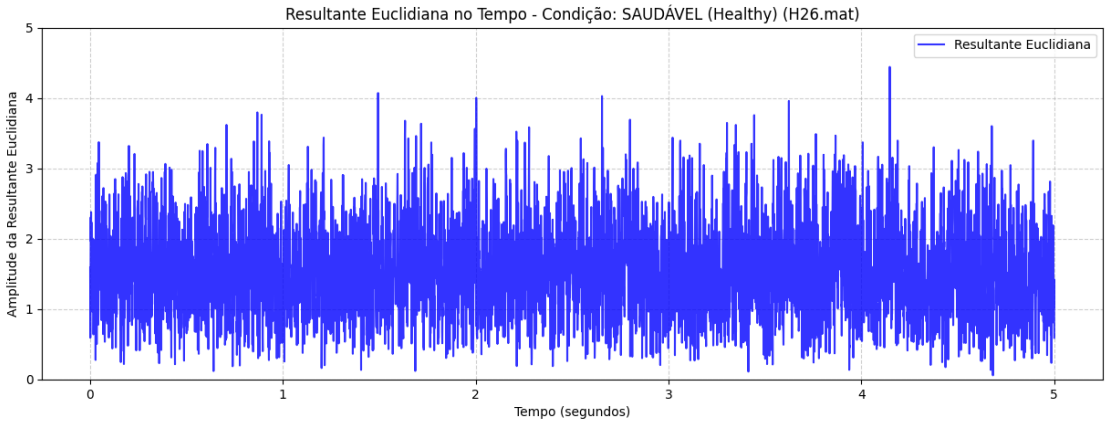


Fonte: Própria

3.2 Sinal da Vibração Saudável e com Falha depois da Resultante Euclidiana

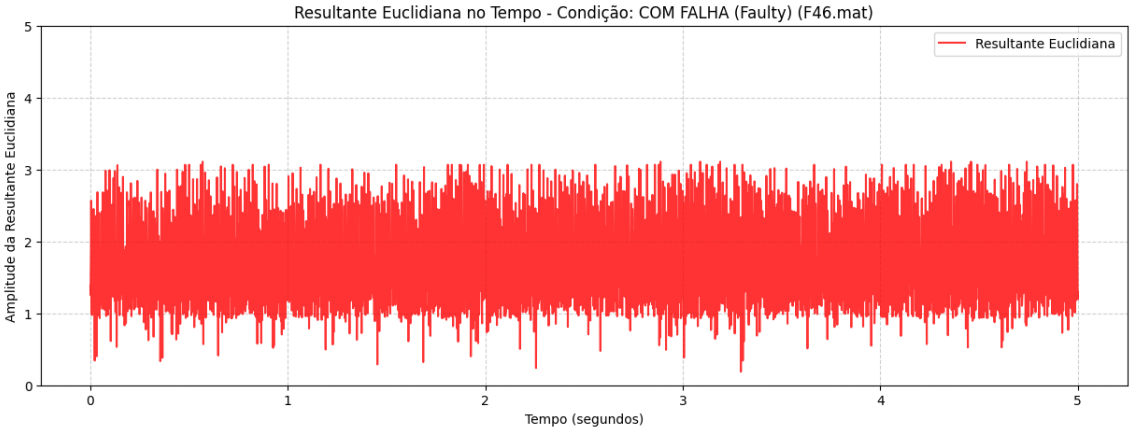
A aplicação da Resultante Euclidiana consolida os 3 sinais axiais temporais de vibração em um vetor único de amplitude, permitindo uma análise centralizada da energia do sistema. Assim, a Resultante Euclidiana atua como um indicador da condição operacional, sintetizando em um único sinal a trajetória temporal que torna possível a distinção entre o estado "Saudável" (Figura 3) e o com defeito (Figura 4) de maneira visual.

Figura 3 – Resultante Euclidiana no Tempo – Condição Saudável



Fonte: Própria

Figura 4 – Resultante Euclidiana no Tempo – Condição Com Falha

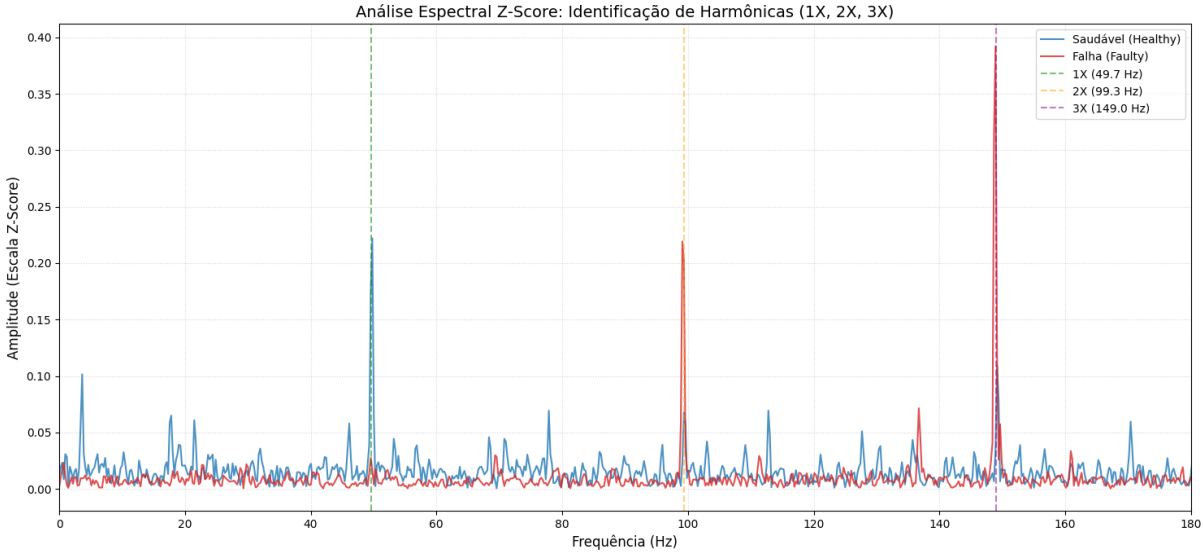


Fonte: Própria

3.3 Análise do Domínio da Frequência

A conversão dos sinais para o domínio da frequência, via FFT (Figura 5), permitiu a validação da velocidade de rotação do motor e a identificação das assinaturas de funcionamento normal na 1ª harmônica e de defeito principalmente na 2ª e nas 3ª harmônicas. A análise do espectro de frequência, executada com o sinal normalizado e escalonado, possibilitou a confirmação da rotação nominal do motor na detecção no primeiro pico de energia na frequência fundamental de 49,8 Hz (Tabela 1) com amplitude de 0.2221 σ, validando a adoção da velocidade de referência em 2980 RPM, já considerando o escorregamento. Esta confirmação de velocidade de rotação é essencial para garantir que as análises futuras estejam embasadas na operação real do motor, permitindo a correta localização dos múltiplos de frequência fundamental (1X, 2X, 3X) que caracterizam fenômenos de desalinhamento e desbalanceamento.

Figura 5 – Análise Espectral Z-Score



Fonte: Própria

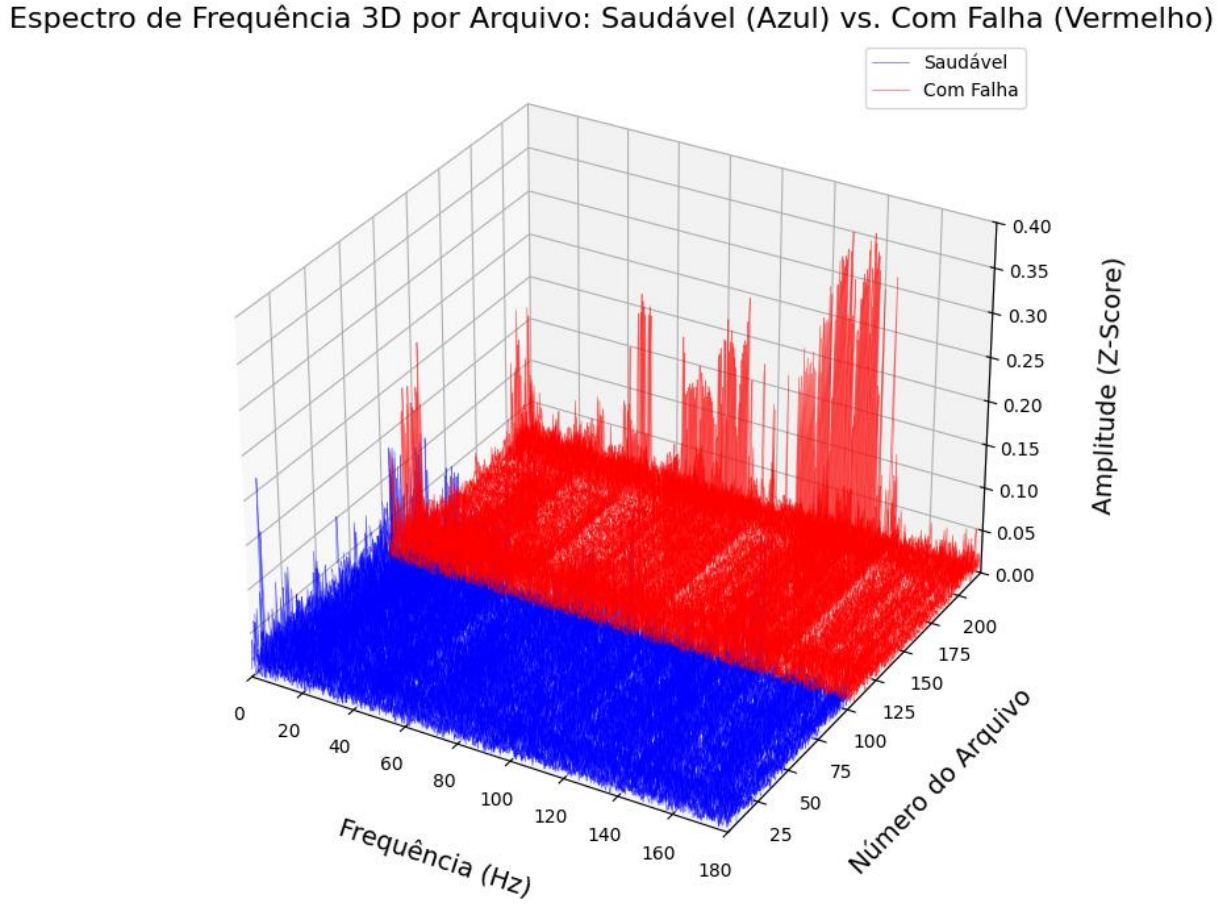
Tabela 1 – Análise Espectral das Harmônicas

```
============================================================
EXTRAÇÃO DE VALORES: ANÁLISE ESPECTRAL DAS HARMÔNICAS
============================================================
CONDIÇÃO: Saudável (H26.mat)
-> Harmônica 1X: Pico Real em  49.8 Hz | Amplitude: 0.2221 σ
-> Harmônica 2X: Pico Real em  99.4 Hz | Amplitude: 0.0676 σ
-> Harmônica 3X: Pico Real em 149.2 Hz | Amplitude: 0.1092 σ
------------------------------------------------------------
CONDIÇÃO: Falha (F46.mat)
-> Harmônica 1X: Pico Real em  49.6 Hz | Amplitude: 0.0275 σ
-> Harmônica 2X: Pico Real em  99.1 Hz | Amplitude: 0.2192 σ
-> Harmônica 3X: Pico Real em 148.9 Hz | Amplitude: 0.3922 σ
============================================================
```

Fonte: Própria

Ao sobrepor os espectros frequência de todos os 220 registros coletados (Figura 6) em um único gráfico com os eixos das variáveis frequência e amplitude, a distinção entre os estados operacionais torna-se mais evidente através do comportamento das amplitudes harmônicas. Enquanto os registros da condição “Saudável” (em azul) apresentam um perfil “Saudável” e de baixa amplitude, os sinais correspondentes ao estado “Falha” (em vermelho) mostram um aumento de energia em zonas específicas, como em torno dos 100 Hz que corresponde a segunda harmônica (2X) também em volta dos 150 Hz, terceira harmônica (3X). Esse acúmulo de energia ao redor das harmônicas funciona como um marcador de diagnóstico. Assim, a análise espectral fornece características importantes, como a amplitude de frequência necessárias para que o classificador identifique padrões de defeito com acurácia.

Figura 6 – Espectro de Frequência 3 Dimensões



Fonte: Própria

3.4 Extração dos Atributos

A etapa de extração de atributos consolidou as informações temporais e de frequência em um conjunto de dados estruturado, permitindo analisar os atributos de forma tabular (Tabela 2). Os dados revelam que variáveis temporais, calculadas a partir da Resultante Euclidiana, como o RMS e o Fator de Crista apresentam uma dispersão controlada, com médias de 1,7275 e 2,3863 e desvio padrão de 0.1162 e 0.5423, respectivamente. No entanto, a análise estatística identifica que a Curtose possui uma variabilidade significativamente maior, atingindo um valor máximo de 5,3450 com desvio padrão de 0.8964 frente a uma média de apenas 0,3147, o que evidencia a presença de amostras com transientes de impacto muito acima da normalidade.

No domínio da frequência, a extração das amplitudes em 1X, 2X e 3X capturou a distribuição de energia característica de máquinas rotativas. A análise dos valores máximos extraídos (0,1942, 0,1574 e 0,2265, respectiva para 1X, 2X e 3X) confirma a predominância de componentes vibratórias em múltiplos da rotação nominal, fornecendo ao modelo as coordenadas necessárias para a separação de classes. O fato da média da amplitude (0.0955) e do desvio padrão da amplitude em 3X (0,0640) serem os mais elevados entre os atributos no domínio da frequência corrobora que esta harmônica atua como um divisor sensível entre os estados “Saudável” e “Falha”.

Conclui-se que a extração de atributos que transforma sinais temporais em valores estatísticos, fornece uma base de dados que já indica, numericamente, diferenças entre as condições operacionais antes mesmo do ajuste de escala final.

Tabela 2 – Dataset Normalizado com 220 Amostras

"DATASET" NORMALIZADO COM 220 AMOSTRAS

	rms	curtose	fator_crista	amp_1x	amp_2x	amp_3x
mean	1.7275	0.3147	2.3863	0.0703	0.0682	0.0955
std	0.1162	0.8964	0.5423	0.0521	0.0390	0.0640
min	1.4806	-0.4443	1.6919	0.0094	0.0138	0.0122
25%	1.6919	-0.1996	1.7825	0.0227	0.0338	0.0403
50%	1.7302	-0.0020	2.4492	0.0554	0.0581	0.0764
75%	1.7503	0.3795	2.6812	0.1062	0.0998	0.1503
max	2.7401	5.3450	5.0584	0.1942	0.1574	0.2265

Fonte: Própria

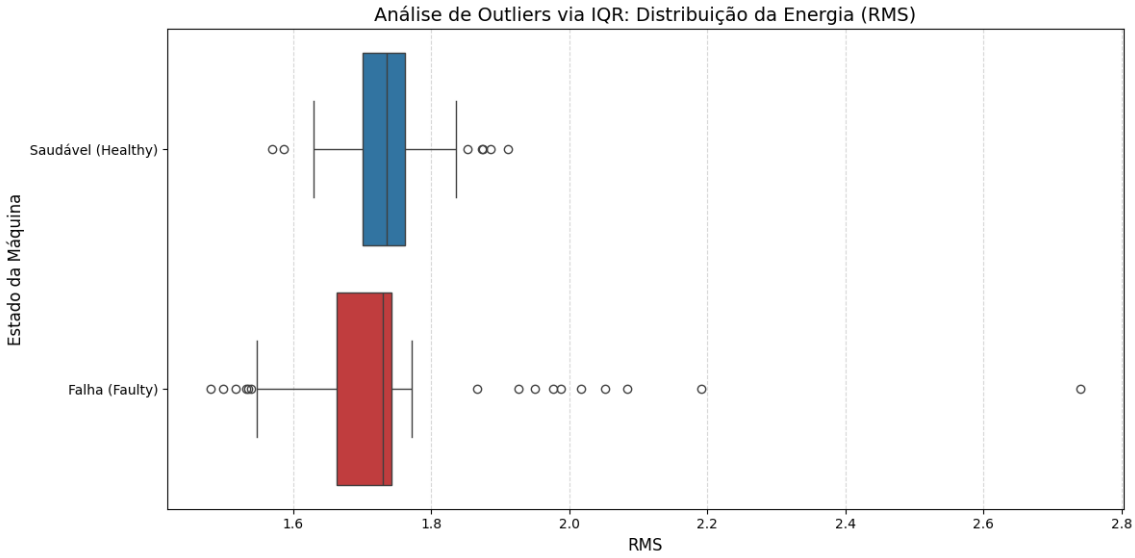
3.5 Tratamento de "Outliers" e Limpeza de Dados

A integridade do diagnóstico automatizado depende da qualidade das amostras de treinamento, o que exigiu a identificação e remoção de "outliers" (Figura 7). Para este fim, utilizou-se o método da Amplitude Interquartílica (IQR), sobre o "dataset" normalizado, estabelecendo limites para a exclusão de amostras espúrias (Tabela 3). A escolha do RMS como a variável de referência para o corte crítico justifica-se por sua natureza física: o RMS é o indicador mais direto da energia eficaz vibratória. Ao observar os gráficos de "boxplot" de todos os atributos (Figura 8), nota-se que enquanto atributos como a Curtose, Fator de Crista e as amplitudes harmônicas possuem uma variabilidade intrínseca associados a falha, o RMS apresenta uma distribuição mais centrada no estado "Saudável".

A aplicação do filtro com IQR resultou na exclusão de 7 amostras do grupo "Saudável" que excederam o limite superior de 1,8520 (Tabela 3), consolidando um "dataset" final de 213 amostras balanceadas (Tabela 4). Decidiu-se preservar todos os dados do estado de falha devido a relevância física do comportamento de falha. Enquanto no estado íntegro os outliers indicam ruídos espúrios que devem ser removidos para evitar alarmes falsos, na classe de falha as flutuações extremas representam a manifestação física real do defeito mecânico. Portanto, eliminar estes pontos comprometeria a representatividade do conjunto de dados de treino. A manutenção destes transientes garante que o classificador KNN reconheça as falhas severas em operação.

A análise comparativa das estatísticas antes (Tabela 2) e após a limpeza (Tabela 5) revela que os atributos tanto do domínio do tempo como da frequência foram praticamente preservados, com variações pequenas, para manter a sensibilidade ao defeito.

Figura 7 – Análise de Outliers via IQR



Fonte: Própria

Tabela 3 – Estatísticas dos Quartis dos Grupos Saudável e Falha

ESTATÍSTICAS DOS QUARTIS DO GRUPO SAUDÁVEL
Q1 (25%): 1.7004
Q3 (75%): 1.7610
IQR: 0.0606
Limite Inferior: 1.6095
Limite Superior: 1.8520 (Corte Crítico)
ESTATÍSTICAS DOS QUARTIS DO GRUPO FALHA
Q1 (25%): 1.6634
Q3 (75%): 1.7421
IQR: 0.0787
Limite Inferior: 1.5453
Limite Superior: 1.8602

Fonte: Própria

Tabela 4 – Quantidade de Amostras após Limpeza

QUANTIDADE DE AMOSTRAS APÓS LIMPEZA
Amostras Saudáveis Originais : 103
Amostras com Falha Mantidas : 117
Amostras Saudáveis Removidas: 7
Total Final (“dataset”) : 213

Fonte: Própria

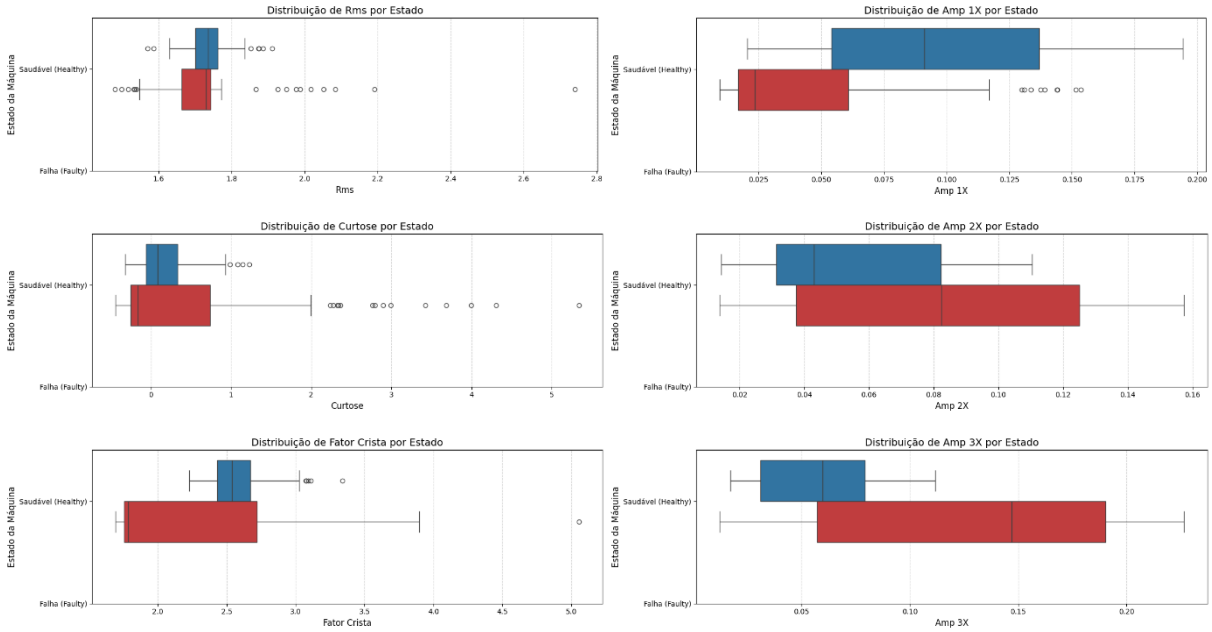
Tabela 5 – Dataset Normalizado e Limpo com 213 Amostras

"DATASET" NORMALIZADO E LIMPO COM 213 AMOSTRAS

	rms	curtose	fator_crista	amp_1x	amp_2x	amp_3x
mean	1.7253	0.3241	2.3831	0.0691	0.0684	0.0967
std	0.1148	0.9092	0.5503	0.0518	0.0393	0.0646
min	1.4806	-0.4443	1.6919	0.0094	0.0138	0.0122
25%	1.6926	-0.2008	1.7816	0.0215	0.0339	0.0391
50%	1.7299	-0.0056	2.4496	0.0532	0.0563	0.0773
75%	1.7494	0.4301	2.6935	0.1057	0.1001	0.1513
max	2.7401	5.3450	5.0584	0.1942	0.1574	0.2265

Fonte: Própria

Figura 8 – Boxplot dos Atributos



Fonte: Própria

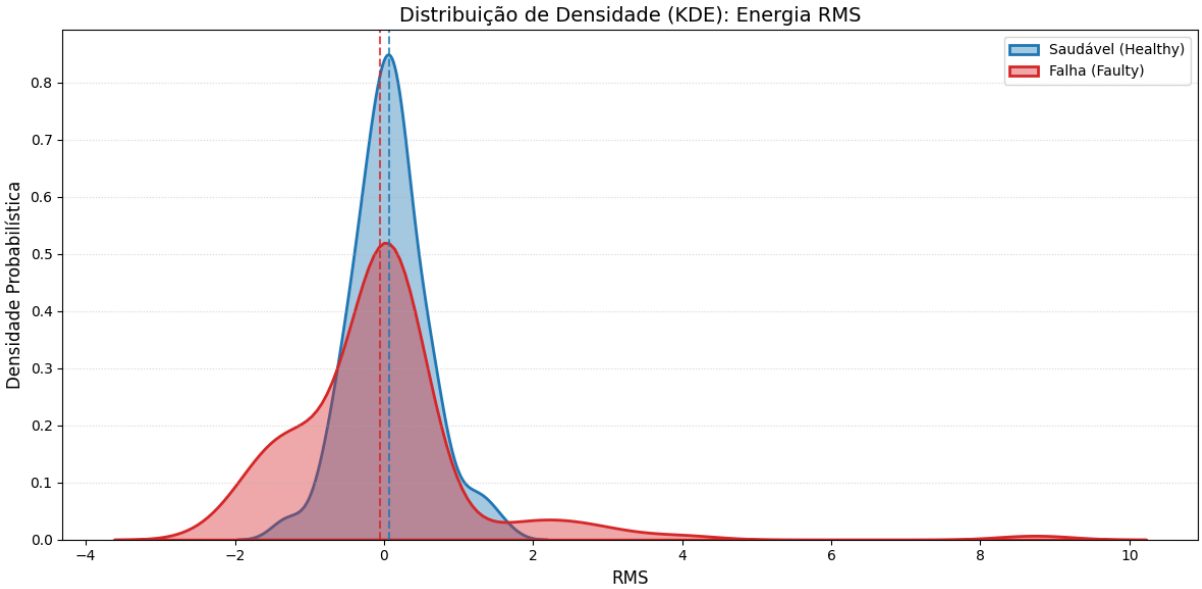
3.6 Análise Estatística da Função Densidade de Probabilidade (PDF)

A análise da PDF (Figura 9) revela a separação clara entre os comportamentos dos estados operacionais. Analisando o "dataset" normalizado e escalonado, nota-se que enquanto a distribuição do grupo "Saudável" apresenta uma concentração simétrica e estreita em torno da média, indicando um regime de vibração estável e previsível, a distribuição do grupo "Falha" exibe uma base significativamente mais larga e uma cauda longa à direita. Esse comportamento é quantificado pela discrepância acentuada na Curtose.

O estado "Saudável" tem Curtose com valor de 0,8227 (Tabela 6), enquanto o estado "Falha" mostra Curtose de 17,9942 (Tabela 6). Esse valor elevado na curtose do estado "Falha" comprova que a anomalia mecânica não apenas eleva a energia média, mas introduz alteração do comportamento da vibração que deforma a normalidade do sinal. A análise da amplitude total, que salta de 2,9503 no estado "Saudável" para 10,8631 na "Falha" (Tabela 6), comprova que o domínio do tempo, quando analisado sob a ótica da probabilidade, já oferece respaldo numérico para a tomada de decisão do modelo para separar as classes "Saudável" e "Falha".

A elevada Curtose de 17,9942 (Tabela 6) da “Falha” corrobora a dispersão de dados visualizada anteriormente no gráfico de “boxplot” do RMS (Figura 7). Isso demonstra que as amostras com maior RMS são as mesmas que apresentam vibrações de impacto severos, justificando o uso do IQR sobre o RMS como parâmetro para identificação de “outliers” e para a limpeza do “dataset”.

Figura 9 – Distribuição de Densidade (KDE): Energia RMS



Fonte: Própria

Tabela 6 – Análise das Estatísticas da Energia RMS

ANÁLISE DAS ESTATÍSTICAS DA ENERGIA RMS

Estado	Média	DesvioPadrão	PicoMax	PicoMin	Curtose	Amplitude
Saudável	0.0657	0.5115	1.5855	-1.3648	0.8227	2.9503
Falha	-0.0578	1.2881	8.7339	-2.1292	17.9942	10.8631

Fonte: Própria

3.7 Análise Comparativa das Densidades de Probabilidade dos Atributos

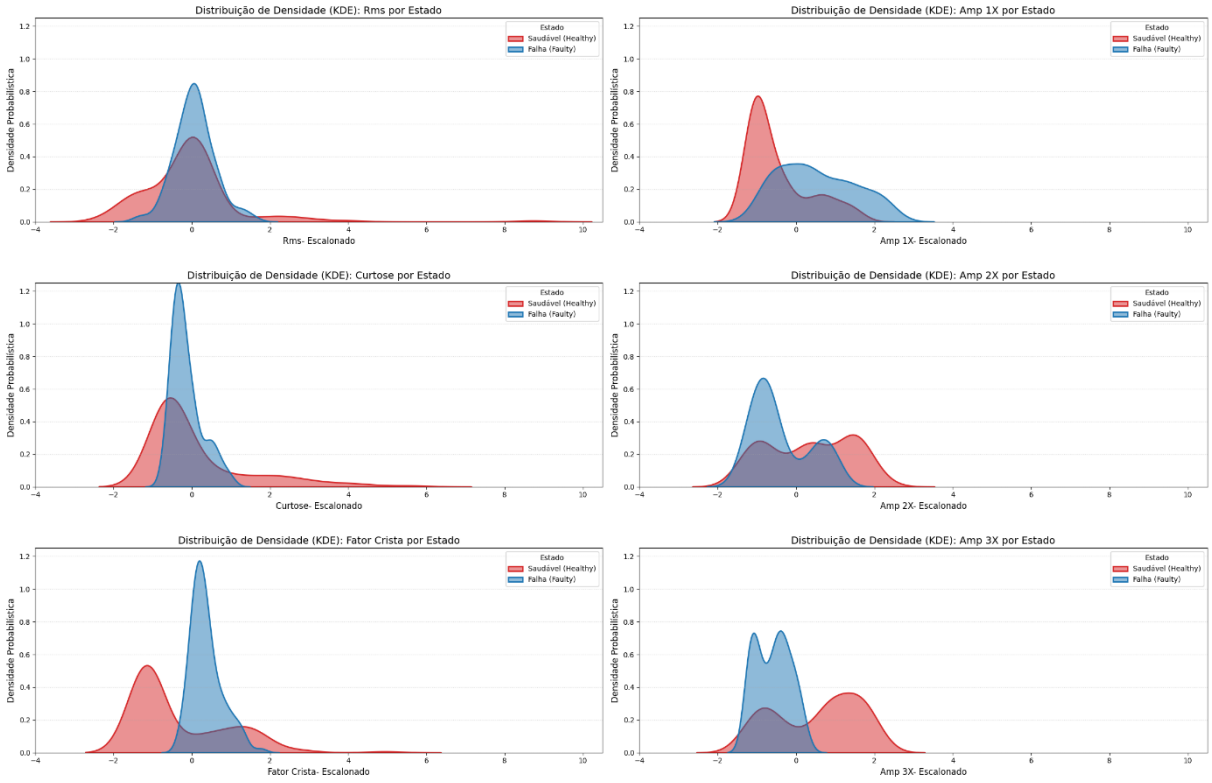
Analisando as curvas PDF para os demais atributos extraídos revela como a assinatura da falha se manifesta de forma diferenciada para cada um dos atributos. Ao observar as PDF dos atributos (Figura 10), RMS, Fator de Crista, Curtose e as amplitudes harmônicas (1X, 2X, 3X), nota-se que ocorre alteração brusca na forma das distribuições de cada atributo se tornando mais um elemento de separação entre as classes para o KNN.

Enquanto o grupo “Saudável” apresenta curvas com amplitude elevada e concentradas (exceto para 1X), indicando um comportamento operacional altamente repetitivo e de baixa variância, já as curvas do estado “Falha” exibem um achatamento e um alargamento das bases e prolongamento das caudas. Este fenômeno demonstra que a falha mecânica introduz uma instabilidade estatística que espalha os valores ao longo do eixo, criando características únicas que o KNN utiliza para delimitar suas fronteiras de decisão entre as classes.

No caso das amplitudes harmônicas, a distribuição “Saudável” e “Falha” é mais difusa, como no caso da amplitude 1X que apresenta a distribuição “Saudável” mais achatada e com base mais longa do que a “Falha”. Portanto, a análise conjunta das curvas PDF indica que a

extração de atributos híbridos, tempo e frequência, oferece uma eficiência, pois se um atributo apresenta uma zona de incerteza, o outro atributo fornece a segregação necessária.

Figura 10 – Distribuição de Densidade (KDE) dos Atributos



Fonte: Própria

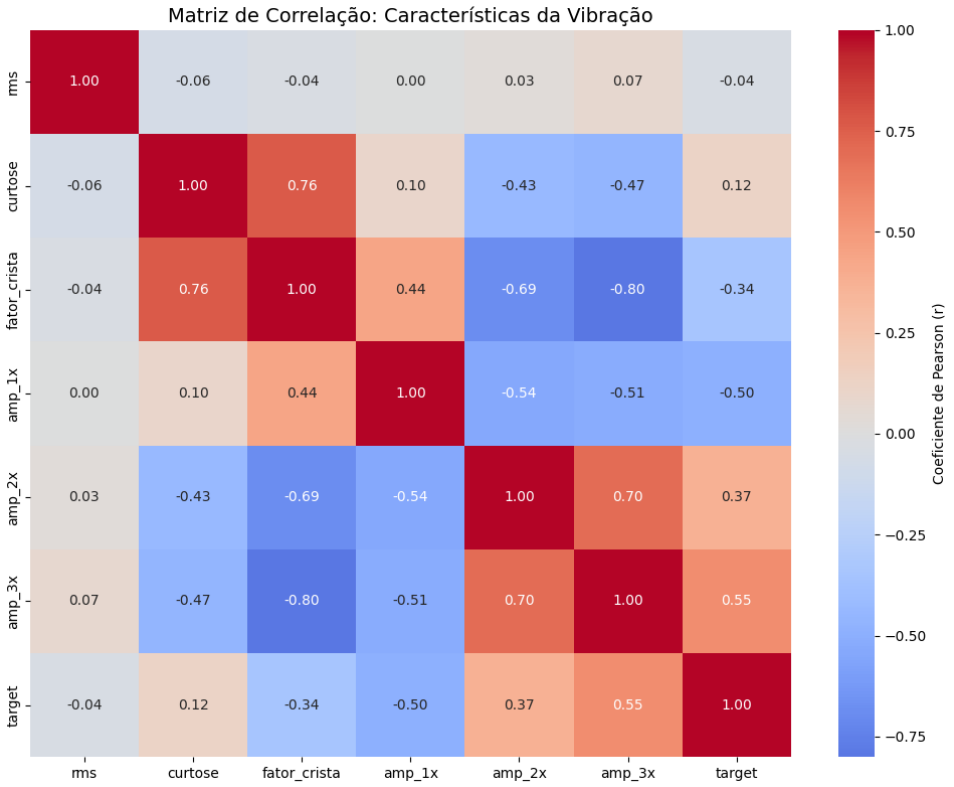
3.8 Análise de Correlação dos Atributos de Vibração

A investigação da correlação linear (Figura 11 e Tabela 7), identifica a relevância dos atributos na distinção entre os estados “Saudável” e “Falha”. O coeficiente de correlação ponto-bisseral (r) revela que a amplitude na terceira harmônica (amp_3x) possui a maior correlação positiva de 0,5532, consolidando-se como o principal indicador para anomalia mecânica. Por outro lado, observa-se uma correlação negativa expressiva na frequência fundamental (amp_1x) de -0,4964.

Este fenômeno indica que, enquanto a energia da falha excita a harmônica superior (amp_3X) na harmônica mais baixa (amp_1X) há uma relação inversa, tornando essa dupla de atributos espectrais uma forte combinação para a distinção entre as classes, ou seja, o alto índice positivo de amp_3X indica um caminho para a anomalia e no outro extremo, o elevado índice negativo de amp_1X leva a normalidade.

O RMS apresentou uma correlação negativa e baixa de -0,0438, sugerindo que a energia eficaz tem pouca significância no contexto geral. Já o Fator de Crista de -0,3436 atua com boa significância para a normalidade. No sentido oposto, que reforça a anomalia mecânica, a harmônica amp_2X (0,3717) e a Curtose (0,1208) confirmam que deteção de defeitos mecânicos é complexa e dependente de atributos com comportamentos distintos.

Figura 11 – Matriz de Correlação: Características da Vibração



Fonte: Própria

Tabela 7 – Correlação dos Atributos de Vibração

CORRELAÇÃO DOS ATRIBUTOS DE VIBRAÇÃO

Atributo	Coeficiente (r)
amp_3x	0.5532
amp_2x	0.3717
curtose	0.1208
rms	-0.0438
fator_crista	-0.3436
amp_1x	-0.4964

Fonte: Própria

3.9 Análise de Generalização via Validação Cruzada (K-Fold)

Para mitigar a variância associada à divisão estática dos dados (treino/teste) e anular qualquer viés de vazamento de dados (“data leakage”) no processo de ajuste do modelo, submeteu-se o “pipeline” completo de classificação a uma validação cruzada estratificada do tipo K-Fold com K=5. Esta abordagem garante que o conjunto total de 213 amostras seja rotacionado de forma que, a cada iteração, quatro blocos (80% dos dados) sejam utilizados exclusivamente para o ajuste e padronização, enquanto o bloco restante (20%) atue como um conjunto de teste independente, sendo que os resultados de cada etapa de teste encontram-se na Tabela 8.

A análise dos resultados revela que o modelo funcionou de maneira robusta e consistente, mantendo uma acurácia média de 96,72% para as validações realizadas. A

ocorrência de uma acurácia de 100% no Fold 2 e uma oscilação mínima para 93,02% no Fold 3 reflete a variabilidade estatística natural decorrente da amostragem interna, mas o baixo desvio padrão observado (0,0236) ratifica a estabilidade do classificador KNN frente a diferentes partições.

Tabela 8 – Relatório de Validação Cruzada

RELATÓRIO DE VALIDAÇÃO CRUZADA (K-FOLD)

Métrica	Valor
Fold 1:	0.9535
Fold 2:	1.0000
Fold 3:	0.9302
Fold 4:	0.9762
Fold 5:	0.9762
Acurácia Média:	0.9672
Desvio Padrão:	0.0236

Fonte: Própria

3.10 Otimização de Hiperparâmetros via Busca em Grade (Grid Search)

Para assegurar a seleção da configuração matemática mais eficiente para o classificador KNN, implementou-se uma estratégia de busca exaustiva em grade (Grid Search) integrada a uma validação cruzada de 5 folds sobre o conjunto de treinamento (X_train, y_train). O objetivo dessa abordagem foi mapear o espaço de hiper parâmetros do algoritmo, testando de forma combinada variações no número de vizinhos (k), nas funções de ponderação de peso e nas métricas de distância (Euclidean e Manhattan). Os parâmetros ótimos identificados pelo algoritmo encontram-se na Tabela 9, enquanto o desempenho médio é apresentado na Tabela 10.

Os resultados revelam que o modelo obteve seu melhor desempenho preditivo, registrando um score médio de acurácia de 97,33% nas partições de validação, ao adotar k=5 vizinhos sob a métrica de distância euclidiana. A seleção da função de peso baseada na distância (“distance”) confere uma característica adaptativa importante ao classificador: em vez de realizar uma votação majoritária simples, o algoritmo atribui maior influência aos vizinhos que estão espacialmente mais próximos da amostra de teste, atenuando o impacto de pontos periféricos localizados próximos às transições de estado.

Dado que o espaço tridimensional de características apresenta alta densidade local e agrupamentos coesos, a distância em linha reta mostrou-se o estimador mais sensível para discriminar a integridade e a severidade dos defeitos.

Tabela 9 – Melhores parâmetros encontrados

MELHORES PARÂMETROS ENCONTRADOS

Parâmetro	Valor
metric	euclidean
n_neighbors	5
weights	distance

Fonte: Própria

Tabela 10 – Melhor score médio na Validação Cruzada

MELHOR SCORE MÉDIO NA VALIDAÇÃO CRUZADA

Métrica	Valor
Melhor score médio na validação cruzada	0.973333

Fonte: Própria

3.11 Validação do Modelo de Classificação e Matriz de Confusão

A etapa de validação final do classificador KNN foi conduzida utilizando o conjunto de teste independente, contendo 64 amostras, correspondentes a 30% do total de 213 amostras resultantes da limpeza dos “outliers” do grupo “Saudável”. O modelo operou sobre os atributos previamente submetidos ao refinamento estatístico e ao escalonamento via Z-Score apresentados no item 3.5 na Tabela 5, garantindo a homogeneidade das grandezas físicas no cálculo das distâncias euclidianas. Os resultados consolidados pela Matriz de Confusão (Tabela 11 e Figura 12) e os índices macro do Relatório de Desempenho (Tabela 12) ratificam a elevada confiabilidade do sistema de diagnóstico.

O modelo demonstrou um comportamento otimizado ao mitigar os riscos operacionais mais críticos do ambiente fabril. A obtenção de uma Especificidade de 100,00% (0 falsos positivos) comprova que o sistema elimina a ocorrência de alarmes falsos no estado estável, evitando paradas de produção desnecessárias. No diagnóstico de anomalias, a Sensibilidade (Recall) atingiu 97,14%, registrando-se uma única omissão de falha entre as 35 amostras degradadas avaliadas. Esse balanço resultou em uma Acurácia Global de 98,44%.

Para avaliar o equilíbrio do classificador em cenários de classes com distribuições reais, analisou-se o F1-Score, que computa a média harmônica entre a precisão e a sensibilidade. O modelo alcançou um índice de 0,9831 para a classe "Saudável" e 0,9855 para a classe "Falha". Esses valores próximos da unidade atestam que a engenharia de atributos híbridos permitiu ao KNN manter uma assertividade simétrica, sem pender a favor de nenhum dos estados operacionais.

Por fim, o desempenho global foi validado pela área sob a curva ROC (AUC-ROC = 1,0000). O cálculo do Intervalo de Confiança (IC 95%) para esta métrica resultou em um limite rígido de [1,0000; 1,0000]. Embora estatisticamente o intervalo reflita a separação geométrica perfeita das fronteiras de decisão no conjunto amostral analisado, em termos práticos de engenharia ele indica que a probabilidade de o modelo classificar incorretamente a severidade de uma vibração sob as mesmas condições experimentais é numericamente desprezível.

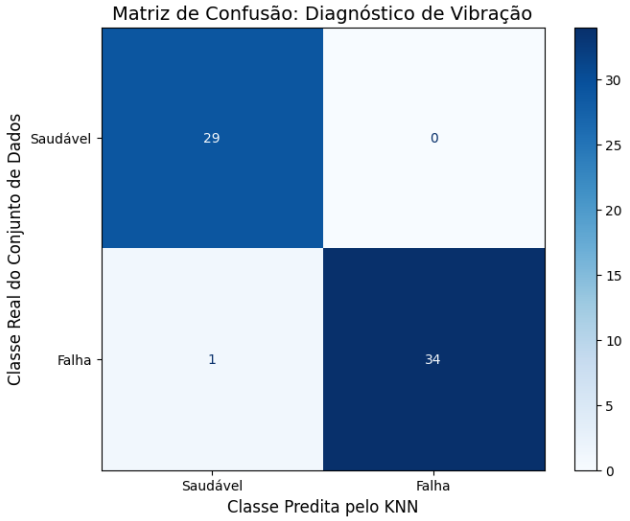
Tabela 11 – Detalhamento da Matriz de Confusão

DETALHAMENTO DA MATRIZ DE CONFUSÃO

Verdadeiros Negativos	(Saudável -> Saudável)	: 29
Falsos Positivos	(Saudável -> Falha)	: 0 (Alarmes Falsos)
Falsos Negativos	(Falha -> Saudável)	: 1 (Omissões de Falha)
Verdadeiros Positivos	(Falha -> Falha)	: 34
Amostras Totais Avaliadas		: 64

Fonte: Própria

Figura 12 – Matriz de Confusão: Diagnóstico de Vibração



Fonte: Própria

Tabela 12 – Relatório de Desempenho

RELATÓRIO DE DESEMPENHO

Métrica (Saudável)	**Valor**	**Descrição**
Precision	0.9667	Precisão para a classe 'Saudável'.
Recall	1.0000	Recall para a classe 'Saudável'.
F1-Score	0.9831	F1-Score para a classe 'Saudável'.
Métrica (Falha)	**Valor**	**Descrição**
Precision	1.0000	Precisão para a classe 'Falha'.
Recall	0.9714	Recall para a classe 'Falha'.
F1-Score	0.9855	F1-Score para a classe 'Falha'.
Acurácia Global	0.9844	Acurácia geral do modelo.
AUC-ROC	1.0000	Área sob a curva ROC.
IC 95% AUC-ROC	[1.0000, 1.0000]	Intervalo de confiança de 95% para o AUC-ROC

Fonte: Própria

3.12 Mapeamento do Espaço de Estados e Fronteiras de Decisão

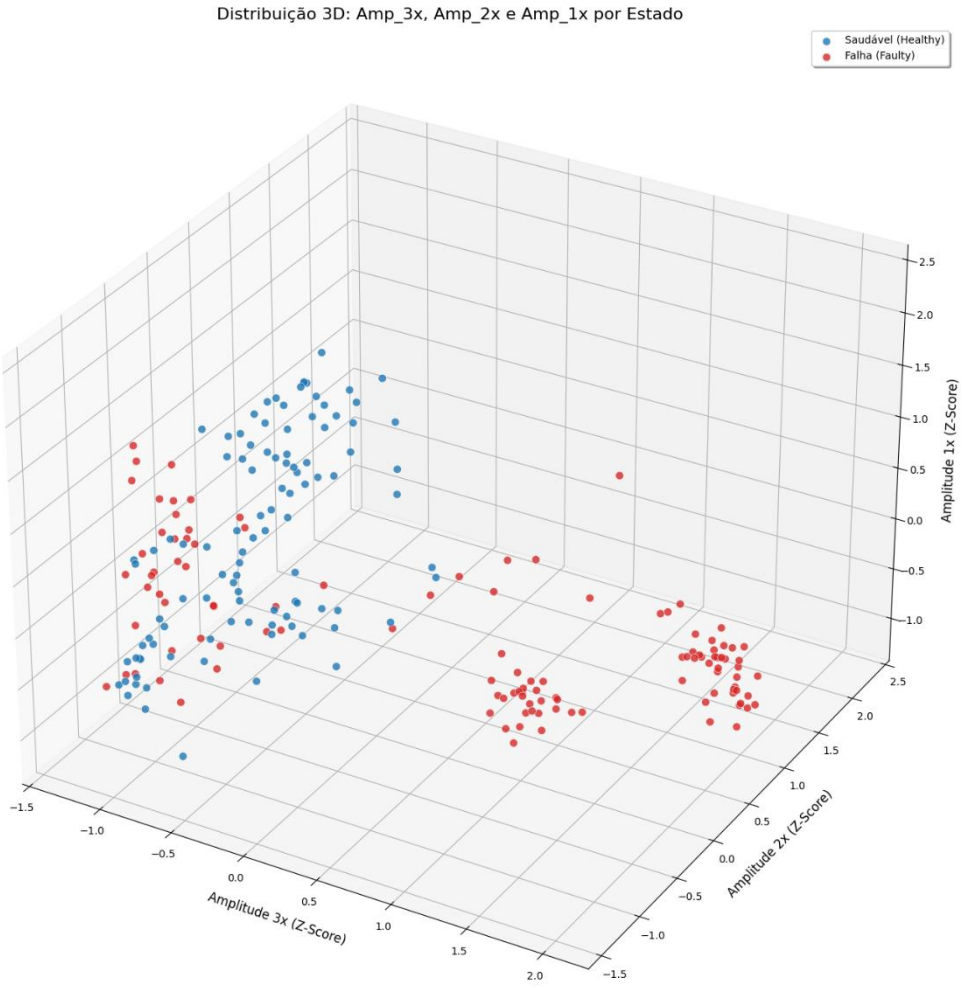
A visualização tridimensional do "dataset" (Figura 13) revela a configuração geométrica que sustenta a alta performance do classificador KNN. Ao projetar as amostras em um espaço de estados composto pelas amplitudes de 3X, 2X e 1X, observa-se uma segregação espacial nítida entre as classes. As amostras correspondentes ao estado "Saudável" (em azul) agrupam-se em uma região de baixa energia e baixa frequência, com baixa amplitude de 1X, amplitude distribuída de 2X e extremamente baixa de 3X, formando uma nuvem de pontos em uma região bem delimitada.

Diferentemente, as amostras do estado "Falha" (em vermelho) distribuem-se em 3 regiões distintas do espaço de atributos de frequência. Uma dispersa entre pontos de estado "Saudável", a segunda praticamente no plano formado entre 2X e 3X nas amplitudes entre 0,5

e 1,0 para a amplitude de 1X na ordem de -1,0 e a última também, aproximadamente, no plano 2X e 3X nas amplitudes aproximadamente entre 2,0 e 1,5 manifestando uma dispersão maior, comparado ao estado “Saudável”, o que reflete o comportamento instável da anomalia mecânica. Esta organização espacial confirma que os atributos espectrais selecionados são preditores altamente eficazes, transformando sinais temporais em coordenadas cartesianas onde a integridade da máquina pode ser analisada.

Portanto a distribuição 3D confirma a eficácia da engenharia de atributos, garantindo que o algoritmo consiga diferenciar entre o “Saudável” e a “Falha” com precisão.

Figura 13 – Distribuição em 3 Dimensões das Harmônicas



Fonte: Própria

4. CONSIDERAÇÕES FINAIS

As considerações finais deste trabalho ratificam a robustez da metodologia proposta, evidenciando que a integração entre o processamento digital de sinais e o aprendizado de máquina oferece uma solução de alta confiabilidade para o diagnóstico de ativos rotativos. A estratégia de fusão de dados triaxiais por meio da Resultante Euclidiana demonstrou ser um passo fundamental, ao consolidar as variações espaciais da vibração em um vetor de magnitude único, preservando a sensibilidade diagnóstica necessária para a detecção de anomalias.

A análise estatística aplicada no pré-processamento mostrou-se determinante para a estabilidade do modelo. A limpeza via IQR foi eficaz na remoção “outliers” que poderiam corromper a interpretação do estado “Saudável”, enquanto o escalonamento via Z-Score

equalizou as escalas de grandezas físicas distintas, como energia temporal e amplitudes espectrais. Esse tratamento preparou os dados adequadamente para a definição de fronteiras de decisão geometricamente nítidas no espaço de atributos. Essa consistência foi maximizada pela otimização via "Grid Search", que determinou matematicamente a arquitetura ideal do classificador KNN com k=5 vizinhos e ponderação baseada na distância.

A transição e classificação do estado "Saudável" para "Falha" manifestou-se por meio de uma redistribuição energética severa, marcada pelas harmônicas de 2ª e 3ª ordem com altos fatores positivos de correlação e do lado oposto a 1ª harmônica com alto fator de correlação, mas negativo, todos validados pelo cálculo da correlação ponto-bisserial. A resposta do classificador confirmou a eficiência desse mapeamento, atingindo uma acurácia global de 98,44% no teste estático e uma acurácia média de 96,72% via validação cruzada *K-Fold*, mitigando o risco de sobreajuste. O equilíbrio do modelo foi ratificado por índices de *F1-Score* superiores a 0,98 em ambas as classes e um intervalo de confiança rígido para o AUC-ROC.

Esse patamar de desempenho posiciona o presente estudo em linha com fronteiras complexas da literatura, demonstrando que o modelo proposto, de baixa complexidade computacional, atinge uma performance estatisticamente equivalente à acurácia de 98,61% obtida por Xia et al. (2018) com Redes Neurais Convolucionais (CNN) aplicadas a múltiplos sensores em cenários similares. Evidencia-se, assim, que a correta estruturação e refinamento estatístico dos atributos superam a necessidade de arquiteturas de aprendizado profundo ("deep learning") para a extração de assinaturas de falha. De grande relevância prática industrial, a especificidade de 100% assegura a eliminação de alarmes falsos em ambiente fabril.

Como perspectiva para trabalhos futuros, vislumbra-se a integração desta metodologia com sistema SCADA (Supervisão, Controle e Aquisição de Dados), permitindo que a detecção de falhas ocorra em tempo real no nível de controle da planta. Dada a realidade industrial onde os ativos raramente possuem dados previamente rotulados, a evolução deste trabalho aponta para o uso de Machine Learning não supervisionado. Tal abordagem permitirá que o sistema aprenda o padrão de comportamento nominal do ativo diretamente com o histórico de variáveis de processo do SCADA, identificando desvios como potenciais falhas sem a necessidade de etiquetas prévias de "Saudável" ou "Falha". Essa transição converterá o diagnóstico estático em um sistema de prognóstico em tempo real, capaz de rastrear a evolução da degradação do ativo em seu regime permanente de operação.

REFERÊNCIAS

BARALDI, Piero *et al.* Hierarchical k-nearest neighbours classification and binary differential evolution for fault diagnostics of automotive bearings operating under variable conditions. **Engineering Applications of Artificial Intelligence**, v. 56, p. 1–13, nov. 2016.

CAESARENDRA, Wahyu; TJAHJOWIDODO, Tegoeh. A Review of Feature Extraction Methods in Vibration-Based Condition Monitoring and Its Application for Degradation Trend Estimation of Low-Speed Slew Bearing. **Machines**, v. 5, n. 4, p. 21, 27 set. 2017.

CERRADA, Mariela *et al.* A review on data-driven fault severity assessment in rolling bearings. **Mechanical Systems and Signal Processing**, v. 99, p. 169–196, jan. 2018.

GAWDE, Shreyas *et al.* Multi-fault diagnosis of Industrial Rotating Machines using Data-driven approach : A review of two decades of research. **Engineering Applications of Artificial Intelligence**, v. 123, p. 106139, ago. 2023.

HAMDAN, Sami *et al.* Julearn: an easy-to-use library for leakage-free evaluation and inspection of ML models. **Gigabyte**, v. 2024, p. 1–16, 7 mar. 2024.

JABLON, Leonardo S. *et al.* Diagnosis of rotating machine unbalance using machine learning algorithms on vibration orbital features. **Journal of Vibration and Control**, v. 27, n. 3–4, p. 468–476, 18 fev. 2021.

JAMES, Gareth *et al.* **An Introduction to Statistical Learning**. New York, NY: Springer New York, 2013. v. 103

KAFEEL, Ayaz *et al.* An expert system for rotating machine fault detection using vibration signal analysis. **Sensors**, v. 21, n. 22, 1 nov. 2021.

KUMAR, H. S.; MANJUNATH, S. H. Use of empirical mode decomposition and K- nearest neighbour classifier for rolling element bearing fault diagnosis. **Materials Today: Proceedings**, v. 52, p. 796–801, 2022.

MAZAREI, Arefeh *et al.* Online boxplot derived outlier detection. **International Journal of Data Science and Analytics**, v. 19, n. 1, p. 83–97, 20 jan. 2025.

PAGAN, Muasir; ZARLIS, Muhammad; CANDRA, Ade. Investigating the impact of data scaling on the k-nearest neighbor algorithm. **Computer Science and Information Technologies**, v. 4, n. 2, p. 135–142, 1 jul. 2023.

RANDALL, Robert B.; ANTONI, Jérôme. Rolling element bearing diagnostics—A tutorial. **Mechanical Systems and Signal Processing**, v. 25, n. 2, p. 485–520, fev. 2011.

SAFIZADEH, M. S.; LATIFI, S. K. Using multi-sensor data fusion for vibration fault diagnosis of rolling element bearings by accelerometer and load cell. **Information Fusion**, v. 18, p. 1–8, jul. 2014.

TANDON, N.; CHOUDHURY, A. A review of vibration and acoustic measurement methods for the detection of defects in rolling element bearings. **Tribology International**, v. 32, n. 8, p. 469–480, ago. 1999.

TUKEY, John W. ..; ANSCOMBE, Francis R. ..; HOAGLIN, David C. .. **Exploratory data analysis**. *[S.l.]*: Addison-Wesley Publishing Company, 1977.

WANG, Lihui; GAO, Robert X. (ORGS.). **Condition Monitoring and Control for Intelligent Manufacturing**. London: Springer London, 2006.

XIA, Min *et al.* Fault Diagnosis for Rotating Machinery Using Multiple Sensors and Convolutional Neural Networks. **IEEE/ASME Transactions on Mechatronics**, v. 23, n. 1, p. 101–110, fev. 2018.